

Document de Sélection du Dataset (DSD)

PlateVision — Système ALPR MINT/DGI Cameroun

Livrable L1 — §3.1.3 Cahier des Charges

Équipe PlateVision

UCAC-ICAM / ULC-ICAM — 3^e année Cycle Ingénieur

June 15, 2026

Contents

1	Méthodologie de sélection	2
2	Tableau comparatif des datasets identifiés	2
3	Dataset retenu et justification	3
4	Limites identifiées et biais	4
5	Plan de prétraitement	4
5.1	Redimensionnement et normalisation	4
5.2	Augmentations	5
5.3	Justification des choix	5

1 Méthodologie de sélection

Conformément au §3.1 du cahier des charges, la sélection du dataset a suivi une **démarche autonome** en quatre étapes :

1. **Veille exhaustive** : recensement de tous les datasets de reconnaissance de plaques accessibles publiquement (Kaggle, Roboflow Universe, Zenodo, GitHub). Critère d'éligibilité minimal : annotations de détection (bounding boxes) et images de qualité suffisante pour YOLOv8 ($\geq 640 \times 640$ pixels).
2. **Évaluation comparative** selon les 7 critères §3.1.1 (pertinence MINT/DGI, double annotation, volume, licence, qualité des annotations, format, biais géographique).
3. **Sélection justifiée** du dataset retenu avec arguments quantitatifs (§3).
4. **Identification des limites et biais** avec plan de mitigation (§4).

2 Tableau comparatif des datasets identifiés

Quatre datasets ont été évalués selon les critères §3.1.1. La note globale est la moyenne pondérée des 7 critères.

Table 1: Comparaison des datasets candidates — notes sur 5

Dataset	Perti.	Ann.	Vol.	Lic.	Q
CCPD (Chinese) (Kaggle – 250k imgs)	2/5 Chine uniquement	5/5 Boîtes + caract.	5/5 250 000 imgs	4/5 Recherche libre	5 Ha
OpenALPR Bench. (GitHub – 900 imgs)	3/5 Multi-pays	3/5 Boîtes seul.	2/5 900 imgs	3/5 Apache 2.0	3 Moy
Roboflow LP De- tect. (Roboflow – 8k imgs)	4/5 Multi-contextes	4/5 Boîtes + classes	3/5 8 000 imgs	4/5 CC BY 4.0	4 Bo
UFPR-ALPR (Zenodo – 4.5k)	5/5 Brésil / CEMAC-like	5/5 Boîtes + car. + OCR	4/5 4 500 imgs	5/5 Recherche libre	5 Très

Détail des critères

Pertinence MINT/DGI : proximité des formats de plaques avec les standards CEMAC (fond de couleur, séparateurs, caractères).

Double annotation : présence d'annotations de détection (bounding boxes) ET de reconnaissance de caractères (texte OCR ground truth).

Volume : nombre d'images — seuil minimal retenu : 4000 images pour un entraînement YOLO fiable.

Licence : utilisabilité dans un contexte académique sans restriction commerciale.

Qualité des annotations : précision des bounding boxes, vérification humaine des labels OCR.

Biais géographique : part de formats non CEMAC dans le dataset (noté de 1=fort biais à 5=faible biais).

3 Dataset retenu et justification

Dataset sélectionné : UFPR-ALPR (+ augmentation Roboflow)

Le dataset **UFPR-ALPR** (Universidade Federal do Paraná – Automatic License Plate Recognition) a été sélectionné comme corpus principal, complété par un sous-ensemble de **Roboflow License Plate Detection** pour augmenter la diversité des conditions d'éclairage.

Justification détaillée

1. **Proximité CEMAC** : les plaques brésiliennes utilisent un format rectangulaire fond blanc / caractères noirs similaire aux plaques camerounaises de série A et B. La disposition (2 lettres – 4 chiffres) est proche du format CEMAC (2–3 lettres + 2–4 chiffres), ce qui réduit le domaine gap par rapport à CCPD (idéogrammes, format complètement différent).
2. **Double annotation complète** : chaque image contient (a) les bounding boxes pour l'entraînement YOLO (Module A2), (b) le texte OCR de référence pour l'évaluation du pipeline A1 et A2, et (c) les métadonnées de captation (distance, angle, éclairage), exploitables pour le Module B.
3. **Conditions variées** : le dataset couvre des prises de vue frontales, latérales ($\pm 30^\circ$), nocturnes et sous pluie, représentatives des conditions des postes de contrôle MINT (bords de route, éclairage naturel variable).
4. **Licence ouverte** : accessible sur Zenodo sans restriction pour la recherche académique, conformément aux exigences de reproductibilité du cahier des charges (§7.2).

Table 2: Composition du corpus d'entraînement PlateVision

Sous-corpus	Images	Plaques annotées	Usage
UFPR-ALPR (train)	3 600	5 400	Entraînement YOLO + Naive Bayes
UFPR-ALPR (val)	450	675	Validation
UFPR-ALPR (test)	450	675	Évaluation finale
Roboflow LP (compl.)	2 000	2 000	Augmentation diversité
Total	6 500	8 750	

Statistiques du dataset final

4 Limites identifiées et biais

Table 3: Limites du dataset retenu et précautions

Limite		Impact	Cas affectés	Précaution
Géographie CEMAC	non	Erreurs OCR sur caractères spéciaux CEMAC	100 % du dataset source	Augmentation + liste blanche
Éclairage tropical	non	Saturation excessive en saison sèche	Prises diurnes ($\sim 60\%$)	Brightness $+40\%$ / -30%
Format non exhaustif	ex-	Plaques jaunes (transport), diplomatiques absentes	$\sim 15\%$ du parc MINT	Liste blanche + seuil conf. bas
Annotations manuelles		Quelques erreurs OCR de référence	$\sim 2\%$ des labels	Nettoyage règle 3-caractères min.

Position du projet Ces limites sont connues et documentées. PlateVision est conçu comme un **prototype de preuve de concept** dans le cadre du PSTNAC 2023–2028. Le déploiement opérationnel nécessiterait la constitution d’un dataset camerounais certifié CEMAC (recommandation Module D, §4.4).

5 Plan de prétraitement

5.1 Redimensionnement et normalisation

- **Détection YOLO (Module A2)** : toutes les images redimensionnées à 640×640 pixels avec *letterboxing* (préservation du ratio, rembourrage gris n°114/255).
- **Reconnaissance de caractères (Module A1 – Naive Bayes)** : découpage des régions de caractères à 28×28 pixels, niveaux de gris, normalisation pixel $[0, 1]$.
- **Embeddings CNN (Module B)** : couche avant-dernière d’un réseau pré-entraîné (MobileNetV2 ou ResNet18), vecteurs de 512 dimensions.

5.2 Augmentations

Table 4: Pipeline d’augmentation appliqué à l’entraînement

Augmentation	Paramètres	Justification
Rotation	± 15	Véhicules pris de biais aux postes MINT
Variation luminosité	Brightness $\pm 40\%$	Soleil équatorial vs. nuageux
Flou de mouvement	Kernel 3–7 px, direction aléatoire	Véhicules en mouvement à 20–60 km/h
Bruit gaussien	$\sigma \in [0.01, 0.05]$	Caméras de surveillance de qualité variable
Simulation pluie	Lignes verticales aléatoires	Saison des pluies camerounaise (6 mois/an)
Échelle	$\times 0.8$ à $\times 1.2$	Distance variable véhicule-caméra

5.3 Justification des choix

- La **rotation** est limitée à ± 15 (et non ± 45) car les plaques aux postes de contrôle sont quasi-frontales. Une rotation excessive créerait des exemples irréalistes.
- La **simulation de pluie** est spécifique au contexte camerounais : 6 mois de saison des pluies impliquent que $\sim 50\%$ des contrôles réels se font sous des conditions dégradées.
- L’**augmentation en échelle** simule les variations de distance véhicule-caméra aux différents types de postes MINT (poste fixe à 2 m vs. barrage mobile à 5–8 m).